Compte rendu, séance 2 (12 novembre 2026)

Rédigé par Elias, d'après le point d'Arno après la séance 2 et l'état de `main` en fin de séance (après fusion des PR #65 à #71).

Objectif de la journée

Rattraper le cadrage de la séance 1 et lancer la conception, pour que tout le monde puisse coder dès la séance 3.

En bref

Toutes les briques du module M1 existent, mais elles ne sont pas encore **branchées de bout en bout**. Le proxy voit les requêtes des 5 IA prioritaires, l'addon d'Arno extrait le prompt et appelle `detect()`, les règles d'Aloïs tournent, le format d'événement est fixé, et l'API Node.js avec sa base MySQL démarre avec Docker Compose. Le tableau de bord lit déjà les alertes de l'API. Tout est fusionné dans `main` en fin de séance. Il reste à relier l'addon à l'API pour que la chaîne marche de bout en bout. M2 (paquets inventés) a ses 4 premières règles, sans exemples ni code pour l'instant.

Présents / absents

Membre	Présent	Remarque
Elias	✅	OK
Imad	✅	OK
Nolan	✅	OK
Arno	✅	OK
Aloïs	✅	OK
Kiliann	✅	OK
Yarkin	❌	Absent, ses cartes ont été reprises par Fati (binôme)
Fati	✅	OK

Avancement des objectifs

#	Objectif	État	Commentaire
1	Charte d'équipe, rôles et Kanban rempli	✅	OK
2	Dépôt rangé, chacun a poussé au moins un commit	🟡	Dépôt rangé ; Yarkin (absent) n'a pas encore de commit
3	Conception : architecture, format d'événement, maquettes, règles M1 et M2	✅	OK : règles M2 écrites, leurs exemples restent à remplir
4	Le proxy voit le trafic ChatGPT (bonus : repère un IBAN)	✅	OK : 5 IA, et l'addon v1 détecte un IBAN (dans `main`)

#	Objectif	État	Commentaire
5	Premier lot de prompts français étiquetés	✅	OK : 150 prompts

Ce qu'on a (livrables par personne)

Brique	Qui	État	Où
Proxy mitmproxy + certificat + procédure	Arno	✅ Fait, testé par Kiliann	`docs/proxy-installation-windows.md`
Où passe le prompt (ChatGPT, Gemini, Mistral, Claude, Copilot)	Arno	✅ Fait (sans compte, sauf Claude)	`docs/captures-sites-ia.md`
Addon CyberSentinel M1 v1 : 5 IA, `detect()`, événements JSON dans un fichier	Arno	🟡 Fait, dans `main` (PR #70) ; pas encore relié à l'API	`proxy/cybersentinel.py`
Liste des sites d'IA, v2 corrigée avec les captures d'Arno	Aloïs	✅ Fait, dans `main` (PR #70)	`rules/sites_ia.yaml`, `docs/sites-ia.md`
Règles M1 (8 règles, 49/49 exemples OK)	Aloïs	✅ Fait, dans `main`	`rules/m1.yaml`, `rules/m1_detect.py`
Note RGPD	Aloïs	✅ Fait	`docs/rgpd.md`
Interface `detect(texte)` + code	Arno, Nolan	✅ v1, dans `main`	`docs/detect.md`, `detection/detect.py`
150 prompts français étiquetés, au format du guide d'annotation	Nolan	✅ Fait	`data/prompts_v1.csv`, `docs/prompts_v1.md`
Modèle baseline TF-IDF	Nolan	🟡 Fait, mais faible (rappel 41 %, fausses alertes 5 %)	`data/baseline.py`, `docs/detect.md`
Test Presidio + métriques cibles	Imad	✅ Fait	`docs/choix-modele-metriques.md`
Charte d'équipe, guide d'annotation, Kanban	Elias	✅ Fait	`docs/`
Format d'événement	Elias	✅ Fait, les 4 points ont été tranchés côté API	`docs/format-evenement.md`, `docs/api.md`
Maquettes des 4 écrans	Fati	✅ Fait	`docs/maquettes/`
Front React + Vite : page « liste des alertes »	Fati	✅ Faite, lit `GET /alerts` toutes les 10 s (PR #71) ; les 3 autres écrans restent à coder	`frontend/`
API Node.js (Express) + base MySQL + Docker Compose	Fati (cartes de Yarkin)	✅ Fait, routes testées	`backend/`, `docs/api.md`
Schéma d'architecture	Fati (carte de Yarkin)	✅ Fait	`docs/architecture.md`
Règles M2 (4 règles : très récent, peu téléchargé, nom proche, inexistant)	Kiliann	🟡 Règles écrites, exemples à remplir	`rules/m2.yaml`

Mesures de la détection

Mesurées par Imad sur la première version des 150 prompts (`docs/choix-modele-metriques.md`). Nolan a depuis réétiqueté le jeu selon le guide (18 prompts par catégorie sensible) : les mesures seront à refaire en séance 3.

Métrique	Règles M1 seules	Règles M1 + Presidio	Objectif
Rappel	60 %	88 %	≥ 90 %
Rappel critique (IBAN, carte, n° de sécu, clés, mots de passe)	72 %	72 %	≥ 95 %
Fausses alertes	8 %	17 %	≤ 10 %
Temps par prompt (95e centile)	0,1 ms	8,3 ms	≤ 50 ms

Points faibles des règles seules, sur cette première version (`data/resultats/prompts_rappel_par_type.csv`) : mots de passe 1/8, santé 0/12, noms de personnes 0/51.

Décisions prises

- **Kanban** : une issue GitHub par tâche (#22 à #57), avec l'étiquette de filière plus `prioritaire` ou `bonus` .
- **Étiquettes du classifieur** : `non_sensible` , `identite` , `finance` , `sante` , `secret_technique` , `donnees_clients` (`docs/guide-annotation.md`).
- **Pile de l'API** : Node.js (Express) + MySQL au lieu de FastAPI + PostgreSQL. Le proxy et la détection restent en Python et parlent à l'API en HTTP et en JSON.
- **Format d'événement** (`docs/api.md`) : champs en français ; `requete_id` ajouté (facultatif, un événement par donnée détectée) ; `source.module` est un champ à part ; une colonne par champ dans la table `evenements` .
- **Dossiers** : `backend/` et `frontend/` sont gardés.
- **Sites d'IA** : ChatGPT sans compte passe par `/unauth-mweb/conversation/updates` ; Gemini envoie le prompt à `geminiweb-pa.clients6.google.com` (l'ancien chemin `StreamGenerate` est abandonné).
- **Fin de séance** : tout est fusionné dans `main` (PR #65 à #71). L'ancien prototype `proxy/addon.py` est supprimé, remplacé par `proxy/cybersentinel.py` .

Ce qui manque pour une démo

Aucun prompt ne va encore du navigateur jusqu'au tableau de bord : l'API et la page des alertes sont reliées, mais pas l'addon. Il reste à :

1. **Relier l'addon à l'API** (Arno) : l'addon écrit aujourd'hui ses événements dans `logs/evenements.jsonl` ; il doit les envoyer à `POST /events` .
2. **Les réglages** : une route que le proxy lira pour savoir s'il faut bloquer, masquer ou alerter chaque type de donnée.

Ensuite seulement : bloquer ou masquer pour de vrai, M2 dans le proxy (pip, npm), un modèle qui monte le rappel.

Risques

Risque	Pourquoi	Parade proposée
Branches qui divergent	Le travail avance sur 4 branches ; tout a été fusionné en fin de séance 2, mais il faut le refaire à chaque séance	Une PR vers `main` en fin de chaque séance, relue par une autre filière
Les sites d'IA changent leurs requêtes	Gemini a déjà changé de domaine ; le mode connecté de ChatGPT n'est pas encore capturé	Refaire les captures avant la démo ; méthode de secours « texte lisible » dans l'addon
Rappel trop bas	60 % avec les règles seules, 88 % avec Presidio mais 17 % de fausses alertes	Renforcer les règles secrets (Aloïs) ; Presidio limité aux noms ; un classifieur
Bloquer casse la page de l'IA	Une réponse 403 au milieu d'un flux peut faire planter l'interface	Commencer par **alerter** seulement, bloquer/masquer à partir de la séance 5
M2 en retard	Les règles M2 n'ont encore ni exemples ni code	Kiliann remplit les exemples en séance 3, avec son binôme Arno
L'API n'est protégée par aucun mot de passe	Elle n'a ni connexion ni rôles	Ne la lancer que sur le réseau de test

Changements pour le planning et le dossier Ydays

- La séance 1 n'a servi qu'à une mise en place légère : la séance 2 a rattrapé le cadrage et lancé la conception.
- La pile de l'API change : Node.js + MySQL.
- Jalons proposés au point d'équipe, à valider en séance 3 : **démo M1 complète à la fin de la séance 5**, M2 à la fin de la séance 7, puis bonus M3/M4 si on est dans les temps (règle d'or de la fiche de direction).

	Séance 3	Séances 4 et 5	Séances 6 et 7	Séances 8 à 11
Jalon	Un faux IBAN dans ChatGPT arrive dans la base	Démo M1 complète	M1 + M2 finis, bonus ?	Soutenance
Cyber (Arno, Aloïs, Kiliann)	Addon relié à l'API, secrets M1, exemples M2	Alerter puis bloquer, M2 dans le proxy	Masquer en direct, M2 bloque pip/npm, lab VM de démo	Bonus M3 agents IA, tests d'attaque, démo finale
Dev (Fati, Yarkin)	Page détail d'une alerte	Page réglages	Page statistiques, alertes M2, tests bout en bout	Bonus M4 affichage, finitions, démo déployée
Data/IA (Elias, Imad, Nolan)	Plus de données, Presidio pour les noms, mesures à chaque PR	Modèle v1 branché, seuil réglable, suivi des métriques	Viser rappel ≥ 90 % et fausses alertes ≤ 10 %, score expliqué	Bonus M4 textes, résultats chiffrés pour le dossier

Objectifs de la séance 3

Objectif de la séance : un faux IBAN tapé dans ChatGPT apparaît dans la base, même si l'écran est encore brut.

Personne	Tâche	Terminée quand
Arno	Faire envoyer les événements de l'addon à `POST /events`	Un faux IBAN dans ChatGPT arrive dans la base
Aloïs	Renforcer les règles `cle_api` et `mot_de_passe`	Secrets ≥ 15/18 sur les 150 prompts
Kiliann	Remplir les exemples de `rules/m2.yaml`, écrire `docs/m2-pip-npm.md`	Chaque règle M2 a ses exemples
Fati	Coder la page « détail d'une alerte » (maquette `docs/maquettes/02-detail-alerte.pdf`)	La page affiche une alerte de la base
Yarkin	Reprendre ses cartes avec Fati (rôle à confirmer)	Rôle noté dans la charte
Elias	Mettre à jour le planning du dossier Ydays	Dossier à jour
Nolan	Réentraîner le modèle avec plus de données	Rappel du modèle mesuré
Imad	Refaire les mesures sur le nouveau `prompts_v1.csv`, préparer ai4privacy, ajouter Presidio (noms) dans `detect()`	Rappel mesuré règles + Presidio dans `main`

À décider en équipe en séance 3

- [ ] Rôle de Yarkin dans l'équipe Dev maintenant que l'API est faite.
- [ ] On teste aussi les IA en mode connecté (ChatGPT, Gemini, Copilot), ou seulement sans compte pour la démo ?
- [ ] Valider les jalons (démo M1 en séance 5, M2 en séance 7).
