Guide d'annotation des prompts

Rédigé par Elias, séance 2. Il sert à étiqueter `data/prompts_v1.csv` et tous les jeux de données qui suivront. **Si un cas n'est pas couvert, on l'écrit dans la colonne `commentaire` et on complète ce guide.**

1. La question à se poser

> « Si ce prompt part chez ChatGPT, est-ce que l'entreprise perd le contrôle d'une donnée qu'elle doit protéger ? »

- **Oui** → `sensible = 1`, puis on choisit la catégorie.
- **Non** → `sensible = 0`, étiquette `non_sensible`.

On juge **le contenu réel** du prompt, pas le sujet. Parler de salaires n'est pas sensible ; coller la fiche de paie de Mme Durand l'est.

2. Les 6 étiquettes

Étiquette	Définition	Exemples typiques
`non_sensible`	Aucune donnée qui identifie une personne, un client ou un secret de l'entreprise	Question générale, code sans secret, données fictives évidentes
`identite`	Données qui identifient **une personne précise**	Nom + adresse, n° de sécurité sociale, date de naissance + nom, n° de passeport, téléphone ou e-mail personnel d'un salarié
`finance`	Données bancaires ou financières exploitables	IBAN, n° de carte, RIB, salaire nominatif, chiffre d'affaires non publié
`sante`	Toute information de santé sur une personne identifiable	Arrêt maladie, diagnostic, handicap, mutuelle avec pathologie
`secret_technique`	Ce qui donne accès aux systèmes de l'entreprise	Clé API, mot de passe, token, chaîne de connexion à une base, clé privée, IP interne + identifiants
`donnees_clients`	Données sur **plusieurs clients** ou issues d'un outil métier	Export CRM, liste de clients avec contacts, historique de commandes, base de prospects

3. Règles de décision

3.1 Une seule étiquette principale

Si un prompt contient plusieurs types de données, on garde **la plus grave**, dans cet ordre :

1. `secret_technique`
2. `sante`
3. `finance`

4. `identite`
5. `donnees_clients`

Les autres catégories présentes vont dans la colonne `etiquettes_secondaires`, séparées par `;`.

> Exemple : « Voici la liste de nos clients avec leurs IBAN » → `finance` (principale), `donnees_clients` (secondaire).

3.2 Identité ou données clients ?

- **Une ou deux personnes nommées** → `identite`.
- **Une liste, un tableau, un export** (3 personnes ou plus, ou un extrait d'outil métier) → `donnees_clients`.

3.3 Les données de contact professionnelles

Un e-mail ou un téléphone **générique** (contact@entreprise.fr, standard) est `non_sensible`. Un e-mail ou un téléphone **nominatif** (jean.martin@entreprise.fr) est `identite`.

3.4 Les faux positifs piégeux → `non_sensible`

Ces prompts **ressemblent** à des fuites mais n'en sont pas. Il faut au moins **un tiers** du jeu de données de ce type.

Piège	Exemple	Étiquette
Valeur masquée ou factice	`FR76 XXXX XXXX XXXX`, `sk-xxxxxxxx`, `password=CHANGEME`	`non_sensible`
Exemple de documentation	« Le format d'un IBAN français est FR76 suivi de 23 caractères »	`non_sensible`
Variable sans valeur	`api_key = os.environ["API_KEY"]`	`non_sensible`
Numéro qui a la forme d'une donnée	n° de commande, référence produit, n° de facture, numéro de ticket	`non_sensible`
Sujet sensible sans donnée	« Comment rédiger un mail pour un arrêt maladie ? »	`non_sensible`
Personnage public ou fictif	« Résume la carrière de Zinedine Zidane »	`non_sensible`

Dans le doute entre une vraie valeur et une valeur factice : **une valeur qui a l'air réelle et complète est sensible**, même si elle est inventée pour le jeu de données (c'est ce que le modèle doit apprendre à attraper).

4. Format du fichier `data/prompts_v1.csv`

Encodage UTF-8, séparateur `,`, champs entre guillemets s'ils contiennent une virgule ou un retour à la ligne.

Colonne	Valeurs	Description
`id`	`p0001`, `p0002`…	Identifiant unique
`prompt`	texte	Le prompt complet, tel qu'un salarié l'écrirait
`sensible`	`0` / `1`	Vérité binaire, utilisée pour le rappel et les fausses alertes
`etiquette`	une des 6 étiquettes	Étiquette principale (règle 3.1)
`etiquettes_secondaires`	ex. `donnees_clients;identite`	Vide si aucune
`contexte`	`mail`, `code`, `rh`, `compta`, `support`, `autre`	Situation métier du prompt
`piege`	`0` / `1`	`1` si c'est un non-sensible piégeux (règle 3.4)
`annotateur`	prénom	Qui a étiqueté
`commentaire`	texte libre	Hésitation, cas non couvert par le guide

Exemple :

```
id,prompt,sensible,etiquette,etiquettes_secondaires,contexte,piege,annotateur,commentaire
p0001,"Peux-tu reformuler ce mail : merci de virer 1 200 € sur FR76 3000 6000 0112 3456 7890
189",1,finance,,compta,0,Nolan,
p0002,"Quel est le format d'un IBAN français ?",0,non_sensible,,compta,1,Nolan,
p0003,"Corrige ce code : conn =
psycopg2.connect(password='Mdp!2026prod')",1,secret_technique,,code,0,Nolan,
```

5. Répartition cible pour les 150 prompts

Étiquette	Nombre visé
`non_sensible` (dont au moins 50 piégeux)	60
`identite`	18
`finance`	18
`sante`	18
`secret_technique`	18
`donnees_clients`	18

Contextes à mélanger : mails, code, RH, compta, support client.

6. Contrôle qualité

- **Double annotation** : 30 prompts tirés au hasard sont étiquetés une deuxième fois par une autre personne (Elias ou Imad). Si l'accord est inférieur à 80 %, on corrige le guide et on relit les cas litigieux.

- **Aucune vraie donnée** : tous les noms, IBAN, numéros et clés sont inventés. Les IBAN et cartes peuvent être valides au sens de la clé de contrôle (générateurs de test), mais ne doivent appartenir à personne.
